

Strukturadaptive Faktorisierung: Empirische Analyse eines hybriden Ansatzes

Thomas Hoffbauer

9. April 2026

Zusammenfassung

Wir untersuchen empirisch die Leistungsfähigkeit eines strukturadaptiven Faktorisierungsverfahrens (AQG) im Vergleich zu klassischen Methoden. Basierend auf Benchmarks über mehrere Größenordnungen zeigen wir, dass AQG signifikante Vorteile bei mittleren Eingabegrößen bietet, während sich beide Verfahren für große Zahlen asymptotisch angleichen. Insbesondere zeigen neue Messungen für 100-stellige Zahlen eine nahezu vollständige Konvergenz der Laufzeiten, was auf die Dominanz der asymptotischen Komplexität hinweist.

1 Einleitung

Die Faktorisierung großer Zahlen ist ein zentrales Problem der algorithmischen Zahlentheorie. Während klassische Verfahren wie Pollard-Rho oder Quadratic Sieve auf generischen Eigenschaften beruhen, untersuchen wir hier einen Ansatz, der strukturelle Eigenschaften der Eingabe ausnutzt.

2 Methodik

Verglichen werden:

- Klassische Faktorisierung
- Strukturadaptives Verfahren (AQG)

Gemessen werden Laufzeiten sowie statistische Kennzahlen (Mittelwert, Median, Quantile).

3 Ergebnisse

3.1 Mittlere Größen (50 Stellen)

- Median AQG: 489 ms
- Median klassisch: 608 ms

AQG zeigt hier einen klaren Vorteil im typischen Fall.

3.2 Übergangsbereich (60–70 Stellen)

- Mittelwerte nahezu identisch
- leichte Vorteile AQG im oberen Quantilbereich

3.3 Große Zahlen (100 Stellen)

Neue Messungen ergeben:

- Durchschnitt AQG: 2569 ms
- Durchschnitt klassisch: 2533 ms
- Median AQG: 2835 ms
- Median klassisch: 2847 ms
- p90 AQG: 3472 ms
- p90 klassisch: 3513 ms
- p95 AQG: 3769 ms
- p95 klassisch: 3902 ms

Diese Werte zeigen:

$$t_{\text{AQG}} \approx t_{\text{klassisch}} \quad (1)$$

mit Abweichungen im Bereich weniger Prozent.

4 Analyse

Die Daten zeigen ein konsistentes Drei-Phasen-Modell:

4.1 Phase I: Kleine Zahlen

Hohe Varianz, strukturabhängiges Verhalten.

4.2 Phase II: Mittlere Zahlen

Signifikante Vorteile von AQG im Median.

4.3 Phase III: Große Zahlen

Nahezu vollständige Konvergenz der Laufzeiten.

5 Interpretation

Die Ergebnisse legen nahe:

$$t(n) = T_{\text{asymptotisch}}(n) + \Delta_{\text{Struktur}}(n) \quad (2)$$

wobei:

- Δ_{Struktur} für mittlere Größen relevant ist
- $T_{\text{asymptotisch}}$ für große n dominiert

Für $n \rightarrow \infty$ gilt empirisch:

$$\Delta_{\text{Struktur}}(n) \rightarrow 0 \quad (3)$$

6 Diskussion

Die Ergebnisse zeigen:

- AQG verbessert die typische Laufzeit für mittlere Instanzen
- keine asymptotische Verbesserung
- starke Konvergenz für große Zahlen

Dies entspricht der Interpretation, dass strukturelle Informationen nur lokale Beschleunigungen ermöglichen.

7 Hybridstrategie

Die Daten motivieren eine adaptive Strategie:

- mittlere Größen: AQG bevorzugen
- große Größen: klassische Verfahren ausreichend

8 Fazit

Wir zeigen empirisch:

- strukturadaptive Beschleunigung im mittleren Bereich
- asymptotische Gleichheit beider Verfahren
- klare Trennung von struktureller und asymptotischer Komplexität

Dies positioniert AQG als effektiven Hybrid-Baustein, jedoch nicht als asymptotischen Durchbruch.

9 Skalierungsverhalten und Resonanzfenster

Die erweiterten Experimente bis 100 und 110 Stellen zeigen ein konsistentes Skalierungsverhalten.

Während AQG im Bereich von etwa 45 bis 60 Stellen signifikante Vorteile im Median aufweist, verschwindet dieser Vorteil für größere Eingaben nahezu vollständig.

Dies legt die Existenz eines sogenannten *Resonanzfensters* nahe, in dem strukturelle Eigenschaften der Eingabe maximal wirksam sind.

Für große Eingaben gilt empirisch:

$$\frac{\Delta_{\text{Struktur}}(n)}{T_{\text{global}}(n)} \rightarrow 0 \quad (4)$$

wobei $T_{\text{global}}(n)$ die dominante asymptotische Laufzeitkomponente darstellt.

10 Seltene strukturelle Abweichungen

Auch für große Zahlen treten vereinzelt signifikante Abweichungen auf, bei denen eines der Verfahren deutlich schneller ist.

Diese Fälle sind jedoch selten und beeinflussen die Gesamtstatistik nur marginal.

Dies deutet darauf hin, dass strukturelle Effekte nicht vollständig verschwinden, sondern als seltene lokale Phänomene bestehen bleiben.

11 Asymptotische Stabilisierung

Die erweiterten Experimente für Eingaben mit mehr als 100 Stellen zeigen nicht nur eine Konvergenz der Laufzeiten, sondern auch eine deutliche Stabilisierung.

Die gemessenen Laufzeiten beider Verfahren liegen im Bereich von etwa 3.5 Millionen Mikrosekunden mit nur geringen relativen Abweichungen.

Dies deutet darauf hin, dass die Laufzeit durch eine dominante globale Komponente bestimmt wird:

$$t(n) \approx T_{\text{global}}(n) \quad (5)$$

Gleichzeitig nimmt die Varianz der Laufzeiten stark ab, was auf eine zunehmende Unabhängigkeit von lokalen strukturellen Eigenschaften hinweist.

12 Universelle Laufzeitklasse

Die beobachtete Konvergenz und Stabilisierung legt nahe, dass verschiedene Faktorisierungsverfahren für große Eingaben in eine gemeinsame effektive Laufzeitklasse fallen.

Strukturelle Unterschiede wirken sich in diesem Regime nur noch marginal aus.

13 Seltene Abweichungen

Trotz der allgemeinen Konvergenz treten vereinzelt Abweichungen auf, bei denen eines der Verfahren signifikant schneller ist.

Diese Ereignisse sind jedoch selten und haben keinen wesentlichen Einfluss auf die Gesamtstatistik.

14 Erweiterte Interpretation

Die Gesamtheit der Daten zeigt:

- ein endliches Effizienzfenster für strukturadaptive Methoden
- eine asymptotische Vereinheitlichung der Laufzeiten
- eine starke Reduktion der Varianz für große Eingaben

Dies legt nahe, dass strukturadaptive Verfahren primär als finite-size Optimierungen zu verstehen sind.

15 Schwere Ausreißer und Verteilung der Laufzeiten

Während die mittleren Laufzeiten für große Eingaben konvergieren, zeigen die Daten weiterhin vereinzelte signifikante Abweichungen.

Diese äußern sich in Form von Ausreißern, bei denen eines der Verfahren deutlich langsamer ist als das andere.

Dies deutet darauf hin, dass die Laufzeitverteilung keine kompakte Streuung besitzt, sondern schwere Tails aufweist.

Formal lässt sich dies wie folgt beschreiben:

$$t(n) = T_{\text{global}}(n) + \Delta(n) \quad (6)$$

wobei gilt:

- $E[\Delta(n)] \rightarrow 0$
- $\text{Var}(\Delta(n))$ bleibt nicht vernachlässigbar

Dies bedeutet, dass strukturelle Effekte im Mittel verschwinden, jedoch als seltene, aber signifikante Abweichungen bestehen bleiben.

16 Implikationen für hybride Verfahren

Die Existenz solcher Ausreißer hat direkte Konsequenzen für hybride Strategien:

- deterministische Auswahlstrategien sind unzureichend
- adaptive oder probabilistische Ansätze sind erforderlich

Insbesondere kann ein Race-Ansatz weiterhin Vorteile bieten, da er solche Ausreißer abfangen kann.

17 Asymptotische Konvergenz und statistische Stabilisierung

Die erweiterten Experimente bis zu 200-stelligen Eingaben zeigen eine nahezu vollständige Konvergenz der Laufzeiten beider Verfahren.

Insbesondere stimmen Mittelwerte, Mediane sowie hohe Quantile (p90, p95) innerhalb weniger Prozent überein.

Dies deutet auf die Existenz einer dominanten globalen Laufzeitkomponente hin:

$$t(n) \approx T_{\text{global}}(n) \tag{7}$$

18 Transienter Charakter struktureller Effekte

Für mittlere Eingaben zeigen sich deutliche strukturelle Effekte, die jedoch für große Eingaben systematisch an Bedeutung verlieren.

Vereinzelte Ausreißer treten weiterhin auf, sind jedoch statistisch instabil und verschwinden im Mittel.

Formal ergibt sich:

$$t(n) = T_{\text{global}}(n), (1 + \varepsilon(n)), \quad E[\varepsilon(n)] \rightarrow 0 \tag{8}$$

19 Schlussfolgerung

Die Ergebnisse zeigen, dass strukturadaptive Verfahren als finite-size Optimierungen zu verstehen sind, während die asymptotische Laufzeit durch eine universelle Komplexitätsstruktur bestimmt wird.