Protokoll der letzten Frage

llama3:latest

26. September 2026

Frage

Nenne in einem Satz die Hauptstadt von Frankreich.

Antwort

Die Hauptstadt von Frankreich ist Paris!

Leistung

Nur diese Frage. Zeiten und Speicher stammen aus diesem Aufruf.

Kennzahl	Wert
Modell	`llama3:latest`
Familie	llama
Parameter	8.0B
Parameteranzahl	8.030.261.248
Quantisierung	Q4_0
Grafikspeicher	5,08 GiB
Modellgröße	5,08 GiB
Nativer Kontext	8192 Tokens
Kontext angefordert	6479 Tokens
Kontext belegt	6479 Tokens
Temperature	0,1617
Top-p	0,4374
Repeat-Penalty	1,2785
Wandzeit	1353,1 ms
Ladezeit	837,6 ms
Zeit ohne Laden	514,6 ms
Bis zum ersten Token	982,2 ms
Prompt-Tokens	23
Prompt-Auswertung	144,6 ms
Prompt-Durchsatz	159,05 Tokens/s
Antwort-Tokens	10
Generierung	369,1 ms
Antwort-Durchsatz	27,09 Tokens/s
Zeit pro Antwort-Token	36,91 ms
Antwortzeichen	40
Zeichendurchsatz	108,4 Zeichen/s
Gesamtzeit laut Ollama	1352,2 ms
Abschluss	stop