Protokoll der letzten Frage

llama3:latest

26. September 2026

Frage

Nenne in einem Satz die Hauptstadt von Frankreich.

Antwort

Die Hauptstadt von Frankreich ist Paris!

Leistung

Kennzahl	Wert
Modell	`llama3:latest`
Familie	llama
Parameter	8.0B
Parameteranzahl	8.030.261.248
Quantisierung	Q4_0
Grafikspeicher	4,66 GiB
Modellgröße	4,66 GiB
Nativer Kontext	8192 Tokens
Kontext angefordert	4068 Tokens
Kontext belegt	4068 Tokens
Temperature	0,1106
Top-p	0,4626
Repeat-Penalty	1,2558
Wandzeit	1344,7 ms
Ladezeit	829,1 ms
Zeit ohne Laden	514,9 ms
Bis zum ersten Token	973,7 ms
Prompt-Tokens	23
Prompt-Auswertung	144,6 ms
Prompt-Durchsatz	159,10 Tokens/s
Antwort-Tokens	10
Generierung	369,5 ms
Antwort-Durchsatz	27,07 Tokens/s
Zeit pro Antwort-Token	36,95 ms
Antwortzeichen	40
Zeichendurchsatz	108,3 Zeichen/s
Gesamtzeit laut Ollama	1344,0 ms
Abschluss	stop

Nur diese Frage. Zeiten und Speicher stammen aus diesem Aufruf.