Protokoll der letzten Frage

gpt-oss:latest

26. September 2026

Frage

Deine Frage

Antwort

Welche Themen interessieren dich am meisten? (Zum Beispiel Bücher, Filme, Technologie, Reisen oder etwas ganz anderes.)

Leistung

Kennzahl	Wert
Modell	`gpt-oss:latest`
Familie	gptoss
Parameter	20.9B
Parameteranzahl	20.914.757.184
Quantisierung	MXFP4
Grafikspeicher	11,86 GiB
Modellgröße	11,86 GiB
Nativer Kontext	131072 Tokens
Kontext angefordert	2525 Tokens
Kontext belegt	2525 Tokens
Temperature	0,0880
Top-p	0,6106
Repeat-Penalty	1,1292
Wandzeit	17615,1 ms
Ladezeit	6097,8 ms
Zeit ohne Laden	11511,0 ms
Bis zum ersten Token	6557,2 ms
Prompt-Tokens	70
Prompt-Auswertung	459,4 ms
Prompt-Durchsatz	152,38 Tokens/s
Antwort-Tokens	333
Generierung	11039,2 ms
Antwort-Durchsatz	30,17 Tokens/s
Zeit pro Antwort-Token	33,15 ms
Antwortzeichen	119
Zeichendurchsatz	10,8 Zeichen/s
Gesamtzeit laut Ollama	17608,8 ms
Abschluss	stop