Protokoll der letzten Frage

llama3:latest

26. September 2026

Frage

Nenne in einem Satz die Hauptstadt von Frankreich.

Durchlauf 1: zufällige Parameter

Kennzahl	Wert
Temperature	0,9370
Top-p	0,2851
Repeat-Penalty	1,2662
Kontext angefordert	6795 Tokens

Antwort

Die Hauptstadt von Frankreich ist Paris!

Durchlauf 2: voroptimierte Parameter

Kennzahl	Wert
Temperature	0,1883
Top-p	0,3127
Repeat-Penalty	1,2737
Kontext angefordert	6637 Tokens

Antwort

Die Hauptstadt von Frankreich ist Paris!

Vergleich

Kennzahl	Zufällig	Voroptimiert	Differenz
Temperature	0,9370	0,1883	-0,7487
Top-p	0,2851	0,3127	+0,0276
Repeat-Penalty	1,2662	1,2737	+0,0075
Kontext angefordert	6795 Tokens	6637 Tokens	-158 Tokens
Kontext belegt	6795 Tokens	6637 Tokens	-158 Tokens
Grafikspeicher	5,11 GiB	5,08 GiB	-0,03 GiB
Wandzeit	16748,6 ms	1358,5 ms	-15390,1 ms
Ladezeit	16123,0 ms	849,6 ms	-15273,4 ms
Zeit ohne Laden	622,5 ms	507,8 ms	-114,7 ms
Bis zum ersten Token	16382,7 ms	995,2 ms	-15387,5 ms
Prompt-Auswertung	259,7 ms	145,5 ms	-114,1 ms
Prompt-Durchsatz	88,57 Tokens/s	158,03 Tokens/s	+69,46 Tokens/s
Antwort-Tokens	10	10	0
Generierung	359,1 ms	360,9 ms	+1,8 ms
Antwort-Durchsatz	27,85 Tokens/s	27,71 Tokens/s	-0,14 Tokens/s
Zeit pro Antwort-Token	35,91 ms	36,09 ms	+0,18 ms
Antwortzeichen	40	40	0
Zeichendurchsatz	111,4 Zeichen/s	110,8 Zeichen/s	-0,6 Zeichen/s
Gesamtzeit laut Ollama	16745,5 ms	1357,4 ms	-15388,1 ms

Die Differenz ist Voroptimiert minus Zufällig. Die Ladezeit des zweiten Durchlaufs ist kürzer, weil das Modell bereits im Speicher liegt. Vergleichbar sind Zeit ohne Laden, Generierung und Durchsatz.