Protokoll der letzten Frage

gpt-oss:latest

26. September 2026

Frage

Deine Frageclear

Durchlauf 1: zufällige Parameter

Kennzahl	Wert
Temperature	0,1193
Top-p	0,5701
Repeat-Penalty	1,5338
Kontext angefordert	5238 Tokens

Antwort

Entschuldigung – ich habe Ihre letzte Nachricht nicht ganz verstanden – könnten Sie bitte genauer erklären, worum es geht?

- Möchten Sie eine Klarstellung zu einer meiner vorherigen Antworten?
[non breaking hyphen] Haben sich Änderungen an Ihrem Anliegen ergeben (z.B., ein neues Thema oder einen anderen Fokus)?
\- Oder benötigen Sie etwas anderes?

Je mehr Details ich habe, desto besser kann ich Ihnen weiterhelfen. Vielen Dank!

Durchlauf 2: voroptimierte Parameter

Kennzahl	Wert
Temperature	0,0344
Top-p	0,7502
Repeat-Penalty	1,1203
Kontext angefordert	5488 Tokens

Antwort

Ich bin mir nicht ganz sicher, was du meinst. Könntest du deine Frage etwas ausführlicher oder klarer formulieren? Dann helfe ich dir gern weiter!

Vergleich

Kennzahl	Zufällig	Voroptimiert	Differenz
Temperature	0,1193	0,0344	-0,0848
Top-p	0,5701	0,7502	+0,1801
Repeat-Penalty	1,5338	1,1203	-0,4134
Kontext angefordert	5238 Tokens	5488 Tokens	+250 Tokens
Kontext belegt	5238 Tokens	5488 Tokens	+250 Tokens
Grafikspeicher	11,86 GiB	11,86 GiB	+0,00 GiB
Wandzeit	18357,9 ms	10287,9 ms	-8070,0 ms
Ladezeit	4398,6 ms	3938,0 ms	-460,6 ms
Zeit ohne Laden	13952,1 ms	6346,4 ms	-7605,8 ms
Bis zum ersten Token	4606,7 ms	4143,0 ms	-463,7 ms
Prompt-Auswertung	208,1 ms	205,0 ms	-3,1 ms
Prompt-Durchsatz	341,12 Tokens/s	346,27 Tokens/s	+5,14 Tokens/s
Antwort-Tokens	421	193	-228
Generierung	13733,3 ms	6138,3 ms	-7595,0 ms
Antwort-Durchsatz	30,66 Tokens/s	31,44 Tokens/s	+0,79 Tokens/s
Zeit pro Antwort-Token	32,62 ms	31,80 ms	-0,82 ms
Antwortzeichen	414	146	-268
Zeichendurchsatz	30,1 Zeichen/s	23,8 Zeichen/s	-6,4 Zeichen/s
Gesamtzeit laut Ollama	18350,7 ms	10284,3 ms	-8066,4 ms

Die Differenz ist Voroptimiert minus Zufällig. Die Ladezeit des zweiten Durchlaufs ist kürzer, weil das Modell bereits im Speicher liegt. Vergleichbar sind Zeit ohne Laden, Generierung und Durchsatz.